

Análise e Criação de Modelos Classificadores de Evasão Acadêmica em Ensino Superior

Mateus Costa Sanches
Instituto Federal de Educação,
Ciência e Tecnologia de São Paulo
Birigui, Brasil
mateus.sanches@aluno.ifsp.edu.br

Abstract—Este projeto contempla uma análise e desenvolvimento de modelos preditores de risco de evasão acadêmica aplicado à uma base de dados pública

Index Terms—data mining, machine learning, university dropout, classification task.

I. INTRODUÇÃO

Segundo o relatório *Education at a Glance 2023*, publicado pela *Organisation for Economic Co-operation and Development*, responsável pela divulgação dos principais indicadores relacionados à educação, aproximadamente 25% dos brasileiros ingressantes em um curso superior de bacharelado abandonam seus estudos no primeiro ano, apenas 38% terminam a graduação dentro do prazo previsto, enquanto 51% se mantêm sem diploma mesmo três anos após o prazo de graduação esperado, como evidenciado em [1]. Isso corrobora com o fato de que a evasão acadêmica constitui um dos problemas mais persistentes enfrentados dentro das instituições de ensino em todo o mundo, esses dados são observados não apenas no Brasil, mas também em diversos outros países.

evasão no ensino superior é um problema complexo e multifacetado, impactando diretamente os índices institucionais e o desenvolvimento social. Diante desse cenário, a aplicação de técnicas de Inteligência Artificial tem se consolidado como uma ferramenta vital de gestão preditiva, permitindo a identificação precoce de discentes propensos a abandonar o curso a partir de suas características demográficas e de desempenho acadêmico [2]. Nesse contexto, o presente trabalho tem como objetivo aplicar as técnicas de Ciência de Dados com embasamento teórico fundamentado em [3] para classificar estudantes quanto ao risco de evasão ou ao sucesso acadêmico. A base de dados utilizada para este projeto é pública, disponibilizada online pelo repositório *University of California, Irvine* (UCI) [4], e originalmente feita como um estudo de caso de um Instituto Politécnico de Portalegre (IPP), em Portugal [5].

II. METODOLOGIA

A metodologia adotada neste trabalho foi dividida em cinco principais etapas norteadoras, de acordo com os conceitos de Ciência de Dados [3]: Análise Exploratória, Pré-processamento, Análise Descritiva, Agrupamento e Classificação. Inicialmente, durante a Análise Exploratória,

a base de dados foi inspecionada para garantir a qualidade das informações utilizadas nos modelos preditivos, além de compreender as características dos dados e identificar possíveis padrões. Posteriormente, técnicas de normalização e redução de dimensionalidade foram aplicadas com a expectativa de se obter componentes que explicassem a variância total dos dados com menos atributos no pré-processamento. Além disso, a visualização de diferentes gráficos e de medidas estatísticas de resumo calculadas na Análise Descritiva revelou-se crucial para compreender como os agrupamentos seriam realizados na etapa futura, ao segmentar os estudantes em grupos com características semelhantes. Por fim, diferentes algoritmos de classificação supervisionada foram empregados para prever o risco de evasão acadêmica, permitindo a comparação de desempenho entre os modelos de acordo com as métricas propostas.

A. Análise Exploratória

A primeira etapa fundamental do projeto envolveu a análise exploratória da base de dados, com o objetivo de reconhecer padrões nos dados, além de entender a dimensionalidade e os tipos de dados da base, por meio de uma limpeza inicial que auxilia na etapa seguinte de pré-processamento.

Dessa forma, a limpeza inicial da base de dados, fundamentada em [6], revelou a existência de 35 atributos numéricos preditores e uma variável de rótulo (totalizando 36 colunas). Observou-se que os dados compreendem aspectos sociais, econômicos e demográficos de 4424 estudantes de variados cursos pertencentes a uma instituição de ensino superior em Portalegre, Portugal. Além disso, verificou-se a inexistência de valores nulos e de *outliers* (observações que não seguem o comportamento ou não possuem a característica comum dos demais), visto que os dados foram submetidos previamente a um processo de filtragem realizado pelos responsáveis pela disponibilização da base no repositório online [4].

Contudo, percebeu-se um acentuado desbalanceamento entre as classes da variável alvo (*Target*), conforme apresentado na Tabela I. Esse fator influencia diretamente o desempenho dos algoritmos de classificação implementados, uma vez que grande parte dos modelos tende a favorecer a classe majoritária, comprometendo a métrica de sensibilidade para os grupos com menor representação. Diante disso, na etapa de classificação, tornou-se necessária a aplicação de

técnicas de balanceamento de dados, permitindo uma posterior comparação entre os resultados obtidos antes e após essa intervenção.

TABLE I
DISTRIBUIÇÃO DOS RÓTULOS DA COLUNA TARGET

Classe	Quantidade de Amostras
Graduate	2209
Dropout	1421
Enrolled	794

B. Pré-Processamento

Durante o pré-processamento dos dados, realizado por meio da linguagem de programação *Python* pela ferramenta de *Notebooks* da plataforma *Jupyter Lab*, diferentes técnicas foram empregadas com o objetivo de preparar a base de dados para as etapas posteriores de análise, agrupamento e classificação. Primeiramente, a matriz de correlação das variáveis foi calculada para a identificação de possíveis relações lineares crescentes ou decrescentes entre pares de variáveis nos dados coletados. Essa abordagem possibilita uma melhor compreensão da dependência entre os atributos, simplificando o volume de dados para as etapas posteriores.

A partir desta análise, observou-se a ausência de correlações acentuadas entre a maioria dos atributos, com exceção das variáveis associadas a créditos, notas e provas de disciplinas cursadas pelos discentes durante o primeiro e segundo semestres letivos. Em seguida, utilizou-se a Análise de Componentes Principais (PCA), buscando reduzir a dimensionalidade dos dados e evidenciar relações lineares que favorecessem a etapa de classificação posteriormente realizada.

É necessário destacar que, previamente à aplicação do algoritmo de redução, os dados foram submetidos à normalização de Máximos e Mínimos, escalonando todas as informações num intervalo de mesma magnitude [0,1]. Esse procedimento foi adotado devido à sensibilidade do algoritmo à escala das variáveis, garantindo que atributos de maior valor não exercessem influência desproporcional na determinação das componentes principais. A normalização foi realizada conforme a fórmula descrita na Equação 1, onde o valor resultante é o atributo original normalizado.

$$a' = \frac{a - a_{\min}}{a_{\max} - a_{\min}} (a'_{\max} - a'_{\min}) + a'_{\min} \quad (1)$$

Essa etapa é fundamental, pois tanto o algoritmo de Análise de Componentes Principais quanto determinados modelos de classificadores aplicados posteriormente, como o *K-Nearest Neighbors* (*K-NN*), são sensíveis à escala dos dados. Ou seja, tendem a priorizar atributos com magnitudes maiores, de forma que atributos com escalas menores fiquem menos aparentes ou sejam ignorados com base na distância calculada devido ao seu baixo valor numérico.

Dessa forma, aplicou-se o PCA com o objetivo de reduzir a dimensionalidade dos dados. Entretanto, verificou-se que as três primeiras componentes explicavam apenas 37,6% da variância total, conforme ilustrado na Fig. 1.




Fig. 1. Projeção 3D das três componentes principais do PCA.

Adicionalmente, conforme ilustrado na Fig. 2, observou-se que foram necessárias 11 componentes para preservar aproximadamente 80% da variabilidade dos dados, ou seja, a técnica de redução aplicada não proporcionou uma simplificação significativa na base de dados. Dessa forma, optou-se por manter a base original nas análises subsequentes.




Fig. 2. Variância acumulada explicada por componentes via PCA.

C. Análise Descritiva

Sequencialmente, a etapa de análise descritiva teve como finalidade caracterizar o comportamento das variáveis por meio de gráficos e medidas de resumo, conforme apresentado em [6]. Essa etapa é indispensável, uma vez que as etapas subsequentes de agrupamento e classificação visam à generalização de padrões a partir dos dados observados. Para isso, realizou-se a separação sistemática entre os 18 atributos categóricos e as 18 variáveis numéricas contidas na base de dados original.

Para a inspeção visual das variáveis numéricas, foram gerados histogramas com empilhamento estruturados de acordo com as frequências observadas para cada classe da variável

alvo (*Target*). Adicionalmente, aplicaram-se gráficos de dispersão por pares, focados especificamente em comparar a evolução das unidades curriculares (notas, aprovações, matrículas, provas, créditos e abandonos de avaliações) dos estudantes entre o primeiro e o segundo semestres letivos. Complementarmente, construíram-se diagramas de caixa (*box-plots*), utilizados para comparar as distribuições quantitativas em relação aos rótulos da variável preditora: *Dropout* (evadido), *Enrolled* (matriculado) e *Graduate* (graduado). Paralelamente, empregaram-se gráficos de setores para atributos com até cinco categorias distintas, permitindo uma visualização mais clara das proporções observadas.

Além da abordagem de visualização gráfica, o conjunto de dados base foi submetido a um mapeamento estatístico detalhado por meio do cálculo de medidas de resumo, separadas em quatro principais blocos analíticos:

1) *Medidas de Tendência Central*: Calculou-se a Média (M), Mediana (MED), Moda (MOD) e o Ponto Médio (PM) dos atributos quantitativos, estabelecendo um referencial dos valores centrais (típicos) dos dados os estudantes.

2) *Medidas de Dispersão*: Computaram-se a Amplitude Total (AT), a Variância (VAR), o Desvio Padrão (DP) e o Coeficiente de Variação em percentagem (CV), visando mensurar a variabilidade e a homogeneidade das notas e índices socioeconômicos.

3) *Medidas de Posição Relativa*: Foram extraídos os limites do Escore- Z , os três Quartis (Q_1 , Q_2 e Q_3) e a Amplitude Interquartil (IQR), fundamentais para a identificação de assimetrias e mapeamento da presença de dados discrepantes (*outliers*).

4) *Medidas de Associação*: Avaliaram-se os coeficientes de covariância e correlação para identificar dependências lineares entre as variáveis preditoras.

Por fim, para os atributos categóricos, mapeou-se a frequência modal em conjunto com o número total de categorias exclusivas, identificando o perfil padrão predominante por atributo no corpo discente estudado.

D. Agrupamentos

Após a caracterização dos dados pela análise descritiva, a etapa de agrupamento foi implementada com o objetivo de segmentar o conjunto de dados em subconjuntos distintos (*clusters*) baseados em medidas de proximidade. Ao aplicar os algoritmos *K-Means* e GMM (*Gaussian Mixture Model*) [3], buscou-se maximizar a homogeneidade interna de cada grupo e a heterogeneidade entre eles. O propósito dessa abordagem foi otimizar a relação *within-cluster* (compactação interna) e *between-cluster* (separabilidade), garantindo que atributos semelhantes permanecessem próximos no mesmo grupo e que os agrupamentos gerados fossem bem distanciados entre si. Essa estruturação dos dados visa revelar subperfis de discentes, fornecendo uma base sólida para que os algoritmos de classificação possam, posteriormente, prever o risco de evasão com maior precisão.

Diante disso, o primeiro método de particionamento aplicado foi o *K-Means*. Esse algoritmo busca agrupar as

observações com base em uma medida de similaridade, utilizando por padrão a distância euclidiana em relação a centroides definidos a partir do parâmetro k , que representa o número predeterminado de agrupamentos. Para determinar o valor mais adequado desse parâmetro, foram empregados conjuntamente o Método do Cotovelo (*Elbow Method*) e o Método da Silhueta (*Silhouette Method*), avaliando-se o comportamento da soma dos quadrados intra-clusters ($WCSS$ – *Within-Cluster Sum of Squares*) e a qualidade da separação entre os agrupamentos para cada valor de k analisado. As fórmulas abaixo referem-se aos cálculos realizados por cada método [3]:

O Método do Cotovelo baseia-se na Soma dos Quadrados Intra-Clusters (*Within-Cluster Sum of Squares* – $WCSS$), que mede o grau de compactação dos agrupamentos formados. Quanto menor o valor do $WCSS$, mais próximas as observações estão de seus respectivos centróides. Sua formulação é apresentada na Equação 2.

$$WCSS = \sum_{j=1}^K \sum_{x_i \in C_j} \|x_i - \mu_j\|^2 \quad (2)$$

Onde K representa o número de *clusters*, C_j corresponde ao conjunto de observações pertencentes ao *cluster* j , x_i é uma observação do conjunto de dados e μ_j é o centróide do *cluster*. O valor ideal de K é geralmente identificado no ponto em que a redução do $WCSS$ passa a ocorrer de forma menos significativa, formando um “cotovelo” no gráfico.

Já o Método da Silhueta avalia simultaneamente a coesão interna dos agrupamentos e a separação entre eles. Para cada observação é calculado um coeficiente de silhueta, definido pela Equação 3.

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \quad (3)$$

Em que $a(i)$ representa a distância média entre a observação i e os demais elementos do mesmo *cluster*, enquanto $b(i)$ corresponde à menor distância média entre a observação i e os elementos dos outros *clusters*. Valores próximos de 1 indicam bom agrupamento, valores próximos de 0 sugerem sobreposição entre grupos e valores negativos indicam possível classificação inadequada. Dessa forma, o índice de silhueta global é obtido pela média dos coeficientes individuais, conforme mostrado na Equação 4.

$$S = \frac{1}{n} \sum_{i=1}^n s(i) \quad (4)$$

Onde n é o número total de observações. O valor de K que produz o maior coeficiente médio de silhueta tende a representar a melhor estrutura de agrupamentos para o conjunto de dados analisado.

Adicionalmente, explorou-se o modelo de agrupamento *Gaussian Mixture Model* (GMM). Diferentemente do *K-Means*, o GMM é um modelo probabilístico que assume que os dados são gerados a partir de uma combinação de

distribuições gaussianas. O treinamento desse modelo é realizado por meio do algoritmo *Expectation-Maximization* (EM), um procedimento iterativo composto por duas etapas. Na etapa de *Expectation*, são calculadas as probabilidades de cada observação pertencer a cada componente gaussiana. Em seguida, na etapa de *Maximization*, os parâmetros de média, variância e peso das distribuições são atualizados com base nas probabilidades estimadas. Essa abordagem permite identificar agrupamentos com diferentes formatos geométricos e atribuir probabilidades de pertencimento às observações (“*soft clustering*”), capturando de maneira mais sensível possíveis nuances nos perfis de risco de evasão.

E. Classificação

Para a etapa final, de classificação, julgou-se necessária a aplicação de duas técnicas de balanceamento de dados, com a finalidade de avaliar e comparar o desempenho dos modelos treinados sob experiências em que as classes estivessem desbalanceadas e balanceadas de maneiras distintas com algoritmos distintos. Conforme evidenciado na Tabela I na subsecção de Análise Exploratória, a variável alvo original exibe uma disparidade volumétrica severa.

Para mitigar o viés em direção às classes majoritárias, adotaram-se abordagens de superamostragem via algoritmo SMOTE (*Synthetic Minority Oversampling Technique*) [6], que realiza o balanceamento da base de dados por meio da geração de amostras sintéticas para as classes minoritárias. Essas novas observações são criadas a partir da interpolação entre uma amostra existente e um de seus vizinhos mais próximos pertencentes à mesma classe. O processo de geração pode ser descrito pela Equação 5.

$$x_{\text{novo}} = x_i + \lambda \cdot (x_{zi} - x_i) \quad (5)$$

Onde x_i representa uma amostra da classe minoritária, x_{zi} corresponde a um dos seus k vizinhos mais próximos e λ é um valor aleatório no intervalo [0,1]. Dessa forma, a nova amostra sintética é gerada numa posição intermediária entre duas observações reais da classe minoritária, contribuindo para o balanceamento do conjunto de dados sem a simples replicação de exemplos existentes.

Além disso, aplicou-se também uma técnica de subamostragem via *Undersampling*, que usa apenas uma parcela da quantidade de dados iguais ao total da classe minoritária. A Tabela II sumariza a distribuição quantitativa das instâncias para cada rótulo de acordo com a estratégia de amostragem empregada.

TABLE II
DISTRIBUIÇÃO DA CLASSE *Target* EM RELAÇÃO AO MÉTODO DE
BALANCEAMENTO APLICADO

Classe	Original (Treino)	SMOTE	Undersampling
Dropout	980	1567	549
Enrolled	549	1567	549
Graduate	1567	1567	549

Como fase conclusiva da metodologia, executou-se a tarefa de classificação para a construção de quatro modelos preditivos distintos seguindo o embasamento teórico [3]: *K-Nearest Neighbors* (KNN), que classifica com base na distância de uma amostra em relação ao resto dos dados já classificados; *Decision Tree* (Árvore de Decisão), que cria uma árvore binária com base nos parâmetros de classificação e nos atributos; *Support Vector Machine* (SVM), que traça diferentes funções que separam os dados; e *Neural Network* (Rede Neural), uma rede de múltiplas camadas de neurónios baseada no *Perceptron*.

Após os experimentos de treinamento e validação de cada arquitetura, de forma a encontrar os melhores parâmetros para os modelos e reduzindo problemas de sobreajuste (*Overfitting*), realizou-se um comparativo direto dos resultados mapeados pelas respectivas matrizes de confusão. A avaliação quantitativa e o desempenho geral dos modelos classificadores [6] foram mensurados a partir das seguintes métricas estatísticas:

1) *Acurácia*: Corresponde ao total de predições corretas realizadas pelo modelo em relação ao total de instâncias avaliadas.

$$\text{Acurácia} = \frac{VP + VN}{VP + VN + FP + FN} \quad (6)$$

2) *Precisão*: Avalia a exatidão das predições positivas, por meio da razão entre verdadeiros positivos e total de elementos classificados como positivos.

$$\text{Precisão} = \frac{VP}{VP + FP} \quad (7)$$

3) *Recall*: Avalia a capacidade do modelo em capturar instâncias pertencentes a uma classe específica.

$$\text{Recall} = \frac{VP}{VP + FN} \quad (8)$$

4) *F1-Score*: Média harmônica entre Precisão e Recall, de forma a fornecer uma medida balanceada para a avaliação da performance do classificador em cenários de dados desbalanceados.

$$F_1 = 2 \cdot \frac{\text{Precisão} \times \text{Recall}}{\text{Precisão} + \text{Recall}} \quad (9)$$

De forma que VP indica dados verdadeiramente positivos, VN representa os verdadeiramente negativos, FP indica dados falsos positivos e FN quantifica os falsos negativos obtidos.

Assim, para a validação das métricas de desempenho, o conjunto de dados foi subdividido na proporção de 70% para a etapa de treinamento e 30% para a fase de testes com a junção do método de Validação Cruzada, que segmenta os dados e treina diversas vezes os modelos. A fim de mitigar o *overfitting* e garantir robustez na escolha dos hiperparâmetros para usabilidade dos modelos preditivos, aplicou-se a técnica de busca em grade em validação cruzada (*Grid Search & Cross-Validation*) sobre o conjunto de treino. Esse procedimento foi executado de forma independente para cada um dos quatro classificadores sob os três cenários amostrais descritos na Tabela II.

A partir das melhores combinações de parâmetros identificadas pelo *GridSearchCV*, os modelos finais foram avaliados utilizando o conjunto de testes, composto por dados inéditos ao processo de treinamento. Em seguida, foram geradas as respectivas matrizes de confusão e calculadas as métricas de desempenho, incluindo a Acurácia global e as métricas macro de Precisão, Recall e F1-Score.

A abordagem macro consiste no cálculo da média aritmética simples dos resultados obtidos individualmente para cada classe, atribuindo o mesmo peso a todas elas. Essa estratégia é particularmente relevante em cenários com desbalanceamento de classes, pois reduz a influência da classe majoritária na avaliação do desempenho das classes minoritárias. Dessa forma, foi possível realizar uma comparação direta e mais equilibrada entre os diferentes modelos treinados para o problema de predição da evasão acadêmica.

III. RESULTADOS OBTIDOS E DISCUSSÃO

A análise dos resultados obtidos neste trabalho permitiu aprofundar a compreensão acerca da estrutura dos dados acadêmicos e socioeconômicos dos estudantes avaliados. Inicialmente, a discussão dos principais achados concentrou-se na avaliação do comportamento do algoritmo de Análise de Componentes Principais (*Principal Component Analysis - PCA*) e na análise da matriz de correlação entre as variáveis.

Conforme descrito na seção de Metodologia, a análise dos componentes principais não evidenciou uma estrutura linearmente separável capaz de distinguir claramente os diferentes perfis estudantis, apresentando cerca de 36% de variância explicada para apenas 3 componentes. Para a obtenção de uma variância explicada superior, constatou-se que a redução de dimensionalidade não seria vantajosa, visto que a eliminação de atributos resultaria na perda de informações potencialmente mais relevantes do que a manutenção das variáveis em sua configuração original. Em contrapartida, a matriz de correlação revelou a existência de algumas associações lineares relevantes entre atributos específicos, destacando-se as fortes correlações positivas observadas entre variáveis relacionadas a provas, notas e créditos das disciplinas frequentadas nas unidades curriculares do primeiro e do segundo semestres.

A análise descritiva também possibilitou delimitar um perfil geral dos estudantes presentes na base de dados a partir das categorias modais dos atributos categóricos e das medidas de resumo calculadas [6]. Os resultados indicaram a predominância de estudantes do sexo feminino, solteiros, jovens, ingressantes por meio da primeira fase do contingente geral, oriundos do ensino secundário, que necessitaram se deslocar de suas cidades de origem para estudar na instituição e matriculados majoritariamente no curso de Enfermagem. Entretanto, os resultados mais relevantes para a análise realizada residem nos grupos menos frequentes e nos padrões associados ao desempenho acadêmico.

O gráfico de dispersão apresentado na Fig. 3 evidencia que estudantes com maiores notas ao final do primeiro semestre tendem a continuar matriculados e a se formarem com maior frequência. Por outro lado, estudantes com menores notas em

algum dos semestres apresentam maior concentração entre os casos classificados como evasão, sugerindo que o desempenho acadêmico em períodos iniciais pode constituir um importante indicador de risco para o abandono do curso.




Fig. 3. Gráfico de dispersão das notas obtidas no primeiro semestre em função da situação acadêmica dos estudantes.

A análise das medidas de resumo corrobora os padrões observados na Fig. 3 e fornece evidências adicionais sobre a relação entre desempenho acadêmico e evasão estudantil. As notas obtidas nas unidades curriculares do primeiro e do segundo semestres apresentaram médias de 10,64 e 10,23, respectivamente, inferiores às medianas correspondentes (12,29 e 12,20). Além disso, a moda igual a zero em ambos os semestres indica que a ausência de aproveitamento acadêmico constitui o resultado mais frequente na amostra. Esse comportamento revela distribuições influenciadas por estudantes com desempenho significativamente inferior ao restante da população, resultado compatível com os padrões observados entre os casos de evasão. Dessa forma, os indicadores descritivos reforçam a hipótese de que dificuldades acadêmicas estão associadas a uma maior propensão ao abandono do curso.

Adicionalmente, observou-se que o número médio de unidades curriculares aprovadas foi inferior ao número médio de unidades matriculadas nos dois semestres analisados. No primeiro semestre, os estudantes cursaram, em média, 6,27 unidades curriculares e obtiveram aprovação em 4,71 delas. No segundo semestre, embora a média de matrículas tenha permanecido praticamente estável (6,23), a média de aprovações reduziu-se para 4,44. Somado a isso, os elevados coeficientes de variação das variáveis relacionadas às aprovações (65,74% no primeiro semestre e 67,96% no segundo) evidenciam uma alta heterogeneidade no desempenho acadêmico, sugerindo a coexistência de diferentes perfis de estudantes na população analisada.

A Fig. 4 apresenta a distribuição das idades no momento de ingresso na instituição de ensino, evidenciando que a maior parte dos estudantes se concentra entre 18 e 22 anos. Esse resultado é consistente com as medidas de resumo obtidas, nas quais a idade média foi de 23,27 anos, a mediana de 20 anos

e a moda de 18 anos, indicando uma distribuição assimétrica à direita, caracterizada pela predominância de ingressantes jovens e pela presença de um grupo menor de estudantes com idades mais elevadas.




Fig. 4. Gráfico de distribuição das frequências de idades em relação ao rótulo dos dados.

De maneira complementar, observa-se que a classe *Dropout* apresenta uma distribuição mais dispersa ao longo das faixas etárias, mantendo frequências relativamente maiores em idades superiores a 25 anos quando comparada às classes *Graduate* e *Enrolled*. Embora os maiores volumes absolutos de evasão também ocorram entre os estudantes mais jovens, em razão da maior representatividade desse grupo na amostra, esse comportamento sugere que ingressantes em idades mais avançadas podem estar associados a uma maior vulnerabilidade ao abandono do curso. Em conjunto, tais evidências indicam que fatores relacionados tanto ao desempenho acadêmico quanto às características demográficas podem contribuir para a compreensão dos diferentes perfis de risco de evasão identificados neste estudo.

A etapa de Agrupamento permitiu identificar padrões relevantes na estrutura dos dados por meio da aplicação do algoritmo *K-Means* [2]. Os resultados obtidos sugerem que as classes mais extremas, *Dropout* e *Graduate*, apresentam características mais bem definidas e, consequentemente, tendem a ser mapeadas com maior facilidade. Em contrapartida, a classe *Enrolled* demonstra maior complexidade, uma vez que seus registros compartilham características com as demais categorias, dificultando sua separação. Como resultado, diversas amostras dessa classe são classificadas incorretamente como *Graduate* ou *Dropout*, evidenciando a existência de regiões de sobreposição entre os grupos e reforçando a dificuldade inerente ao problema de classificação.

A análise conjunta dos métodos do Cotovelo e da Silhueta indicou que a configuração mais adequada para o algoritmo *K-Means* corresponde à utilização de dois agrupamentos. Conforme apresentado na Fig. 5, observa-se uma redução expressiva da Soma dos Quadrados Intra-Clusters (*WCSS*) ao passar de um para dois grupos. A partir desse ponto,

a diminuição do indicador ocorre de forma mais gradual, caracterizando o ponto de inflexão conhecido como “cotovelo” e indicando que o acréscimo de novos agrupamentos produz ganhos limitados na representação da estrutura dos dados.




Fig. 5. Gráfico dos resultados obtidos pelo Método do Cotovelo para determinação do número ideal de clusters no algoritmo K-Means.




Fig. 6. Gráfico dos resultados obtidos pelo Método da Silhueta para determinação do número ideal de clusters no algoritmo K-Means.

Essa conclusão é corroborada pelo Método da Silhueta, apresentado na Fig. 6, que atingiu seu maior coeficiente médio para $K = 2$. Esse resultado indica que os elementos de cada agrupamento possuem elevada similaridade interna e boa separação em relação aos elementos do outro *cluster*. Para valores superiores de K , observa-se uma redução do coeficiente de silhueta, sugerindo que a subdivisão dos dados em mais grupos compromete a qualidade dos agrupamentos.

Com a definição de dois agrupamentos como configuração ideal, o algoritmo *K-Means* foi aplicado ao conjunto de dados para a formação dos *clusters*. A visualização resultante, apresentada na Fig. 7, evidencia a distribuição das observações nos agrupamentos identificados pelo algoritmo, bem como a posição dos respectivos centróides. Observa-se que os dados

tendem a se organizar em dois grandes grupos, corroborando os resultados obtidos pelos métodos do Cotovelo e da Silhueta.

Além disso, a presença de regiões de interseção entre os agrupamentos reforça a dificuldade de separação de algumas amostras, especialmente aquelas pertencentes à classe *Enrolled*, cuja proximidade com as demais categorias contribui para a ocorrência de classificações equivocadas nos modelos supervisionados.




Fig. 7. Visualização dos agrupamentos obtidos pelo algoritmo K-Means com dois clusters.

Portanto, os resultados indicam que a estrutura natural da base de dados é melhor representada por dois agrupamentos principais. Tal comportamento sugere a existência de dois perfis predominantes de estudantes, enquanto a classe *Enrolled* ocupa uma posição intermediária entre eles, o que ajuda a explicar a maior dificuldade observada na sua classificação ao longo dos experimentos realizados.

A. Comparativo dos Modelos em Relação ao Balanceamento

Após a análise dos agrupamentos, procedeu-se à etapa de classificação dos dados [3]. Os modelos avaliados foram comparados por meio das métricas de acurácia, precisão, recall e F_1 -Score, permitindo uma análise quantitativa do desempenho de cada abordagem nos diferentes cenários experimentais. A Tabela III apresenta uma visão consolidada dos resultados obtidos, possibilitando a comparação entre os algoritmos e as estratégias de balanceamento empregadas.

De forma geral, os melhores resultados foram obtidos pelos modelos SVM e Rede Neural aplicados ao conjunto de dados original, ambos alcançando acurácia de 0,76 e F_1 -Score de 0,68. Observa-se também que a aplicação do SMOTE [6] não resultou em ganhos significativos de desempenho para nenhum dos classificadores, enquanto a redução de dimensionalidade apresentou resultados competitivos, especialmente para o SVM e a Rede Neural, mantendo métricas próximas às obtidas com os dados originais.

TABLE III
COMPARAÇÃO GERAL DOS CLASSIFICADORES UTILIZADOS POR MÉTRICAS DE DESEMPENHO

Algoritmo	Modelo	Acc	Prec	Rec	F1
KNN	Original	0.68	0.60	0.54	0.53
	SMOTE	0.60	0.57	0.57	0.56
	Red. Dados	0.61	0.62	0.59	0.59
Árvore Decisão	Original	0.73	0.69	0.64	0.65
	SMOTE	0.70	0.65	0.65	0.65
	Red. Dados	0.69	0.67	0.66	0.65
SVM	Original	0.76	0.71	0.68	0.68
	SMOTE	0.71	0.65	0.65	0.65
	Red. Dados	0.73	0.71	0.70	0.69
Rede Neural	Original	0.76	0.71	0.68	0.68
	SMOTE	0.73	0.67	0.67	0.67
	Red. Dados	0.73	0.70	0.70	0.69

1) *K-Nearest Neighbors*: Os melhores hiperparâmetros encontrados para o algoritmo *K-Nearest Neighbors* (*K*-NN) foram $k = 19$ e distância Euclidiana para o conjunto original; $k = 3$ e distância Euclidiana para o conjunto balanceado com SMOTE; e $k = 15$ e distância Euclidiana para o conjunto submetido à redução de dimensionalidade. O modelo treinado com os dados originais apresentou a maior acurácia (0,68), enquanto a redução de dimensionalidade produziu os melhores valores de precisão (0,62), recall (0,59) e F_1 -Score (0,59). Já o conjunto balanceado com SMOTE obteve desempenho inferior em praticamente todas as métricas avaliadas.

Os resultados indicam que o *K*-NN foi sensível às alterações realizadas nos dados, principalmente devido à sua dependência do cálculo de distâncias entre amostras. A redução de dimensionalidade contribuiu para um melhor equilíbrio entre as métricas, possivelmente pela remoção de atributos redundantes ou pouco informativos, mitigando os efeitos da alta dimensionalidade. Em contrapartida, o balanceamento por SMOTE [6] não trouxe ganhos expressivos para o modelo, sugerindo que a geração de amostras sintéticas não favoreceu a definição das vizinhanças utilizadas pelo classificador.

2) *Árvore de Decisão*: Para a *Árvore de Decisão*, as melhores configurações encontradas utilizaram profundidade máxima igual a 5 para o conjunto original, 19 para o conjunto balanceado com SMOTE e 3 para o conjunto com redução de dimensionalidade. O melhor desempenho geral foi obtido com os dados originais, alcançando acurácia de 0,73, precisão de 0,69, recall de 0,64 e F_1 -Score de 0,65. As abordagens com SMOTE e redução de dimensionalidade apresentaram resultados bastante próximos, mantendo o F_1 -Score em 0,65.

A pequena variação observada entre os cenários demonstra que a *Árvore de Decisão* foi o modelo mais robusto em relação às técnicas de pré-processamento aplicadas. O aumento significativo da profundidade ótima após o SMOTE sugere um acréscimo na complexidade do espaço de decisão, enquanto a redução de dimensionalidade permitiu a construção de uma árvore muito mais simples sem perda significativa de desempenho. Dessa forma, embora os dados originais tenham produzido os melhores resultados, a *Árvore de Decisão* mostrou estabilidade e boa capacidade de adaptação às diferentes abordagens empregadas.

3) *Support Vector Machine*: O *Support Vector Machine* (SVM) apresentou um dos melhores desempenhos entre os classificadores avaliados. Os melhores hiperparâmetros encontrados foram $C = 100$ e *kernel* linear para o conjunto original; $C = 100$ e *kernel* RBF para o conjunto balanceado com SMOTE; e $C = 10$ e *kernel* linear para o conjunto com redução de dimensionalidade. O modelo treinado com os dados originais obteve acurácia de 0,76, precisão de 0,71, recall de 0,68 e F_1 -Score de 0,68, enquanto a redução de dimensionalidade proporcionou o melhor F_1 -Score (0,69) e recall (0,70).

A mudança do *kernel* linear para RBF após a aplicação do SMOTE sugere que o balanceamento tornou a distribuição dos dados mais complexa, exigindo fronteiras de decisão não lineares. Entretanto, essa alteração não resultou em melhorias de desempenho, visto que todas as métricas sofreram redução. Por outro lado, a redução de dimensionalidade manteve resultados próximos aos obtidos com os dados originais e produziu o melhor equilíbrio entre precisão e recall. Esses resultados indicam que o problema possui uma estrutura relativamente bem separável e que a eliminação de atributos redundantes favoreceu a capacidade de generalização do SVM.

4) *Multi-Layer Perceptron*: A Rede Neural *Multi-Layer Perceptron* (MLP) apresentou desempenho semelhante ao SVM, figurando entre os melhores modelos avaliados. Os melhores hiperparâmetros encontrados foram uma camada oculta com 32 neurônios e ativação tanh para o conjunto original, e uma camada oculta com 64 neurônios para os conjuntos balanceado e reduzido, utilizando ativações *ReLU* e tanh, respectivamente. O conjunto original alcançou acurácia de 0,76, precisão de 0,71, recall de 0,68 e F_1 -Score de 0,68, enquanto a redução de dimensionalidade obteve o maior F_1 -Score (0,69) e recall (0,70).

O aumento da complexidade da arquitetura após o balanceamento por SMOTE sugere que as amostras sintéticas exigiram maior capacidade de representação da rede neural. Apesar disso, houve redução das métricas de desempenho, indicando que o balanceamento não trouxe benefícios significativos para o modelo. Em contrapartida, a redução de dimensionalidade preservou as informações mais relevantes do conjunto de dados e favoreceu a generalização da rede, produzindo o melhor equilíbrio entre precisão e recall. Assim como observado para o SVM, os resultados indicam que a redução de dimensionalidade foi mais eficaz do que o balanceamento por SMOTE para este problema.

Por conseguinte, observou-se que a redução de dimensionalidade foi a estratégia de pré-processamento que apresentou os melhores resultados para a maioria dos classificadores, proporcionando os maiores valores de F_1 -Score para K -NN, SVM e MLP, além de manter um desempenho competitivo para a Árvore de Decisão. Em contrapartida, o balanceamento artificial por SMOTE [5] não produziu ganhos significativos e, na maior parte dos casos, resultou em redução das métricas avaliadas. Esses resultados sugerem que a remoção de atributos redundantes ou pouco relevantes teve maior impacto na capacidade de generalização dos modelos do que o balanceamento

artificial das classes para o conjunto de dados estudado.

IV. CONCLUSÃO

A. Desafios Técnicos

Durante o desenvolvimento deste trabalho, um dos principais desafios encontrados foi o tratamento do desbalanceamento presente no conjunto de dados, uma vez que essa característica pode influenciar diretamente o treinamento e a avaliação dos classificadores. Para mitigar esse problema, foi empregada a técnica SMOTE, permitindo analisar os impactos do balanceamento artificial das classes no desempenho dos modelos.

Outro desafio relevante esteve relacionado à elevada dimensionalidade dos dados e à identificação dos atributos mais representativos para a tarefa de classificação. A aplicação de técnicas de redução de dimensionalidade, bem como técnicas de visualização de possíveis correlações entre atributos e métodos de agrupamento não supervisionados, permitiu avaliar a influência da simplificação do espaço de atributos sobre a capacidade de generalização dos algoritmos. Além disso, foi necessário realizar o ajuste de hiperparâmetros por meio de busca sistemática, garantindo que cada modelo fosse avaliado em sua configuração mais adequada.

B. Conclusões Finais

O presente trabalho teve como objetivo avaliar o desempenho de diferentes algoritmos de aprendizado de máquina na tarefa de predição da evasão acadêmica, comparando os efeitos do balanceamento de classes por meio do SMOTE e da redução de dimensionalidade sobre os resultados obtidos. Os experimentos realizados demonstraram que os modelos *Support Vector Machine* e *Multi-Layer Perceptron* apresentaram os melhores desempenhos gerais, alcançando acurácia de até 0,76 e F_1 -Score próximo de 0,70.

Os resultados indicaram que a redução de dimensionalidade foi a estratégia de pré-processamento mais eficaz para o conjunto de dados estudado, proporcionando melhorias ou manutenção do desempenho para a maioria dos classificadores avaliados. Em contrapartida, a aplicação do SMOTE não resultou em ganhos significativos e, em diversos cenários, ocasionou redução das métricas de desempenho. Esses resultados sugerem que a eliminação de atributos redundantes ou pouco relevantes exerceu maior influência na qualidade da classificação do que o balanceamento artificial das classes.

Ademais, ao confrontar os achados deste estudo com a literatura correlacionada, observa-se que os dois classificadores de melhor desempenho obtiveram índices de acurácia superiores aos reportados na referência [4]. Embora uma comparação direta estrita seja limitada pelas inevitáveis divergências nos cenários experimentais e nos modelos desenvolvidos subjacentes, esses resultados sugerem a robustez e a eficácia das estratégias de modelagem e pré-processamento adotadas neste trabalho, sinalizando o potencial dos modelos propostos para o contexto avaliado.

Dessa forma, conclui-se que a seleção e transformação adequadas dos atributos desempenham papel fundamental na

construção de modelos preditivos para evasão acadêmica. Como trabalhos futuros, sugere-se a investigação de outras técnicas de balanceamento de dados, métodos mais avançados de seleção de atributos e algoritmos aplicados, bem como a avaliação de arquiteturas neurais mais complexas e estratégias de otimização adicionais.

REFERENCES

- [1] G1, “51% dos brasileiros que entram na faculdade não se formam nem 3 anos após o prazo previsto,” Sep. 9, 2025. [Online]. Available: <https://g1.globo.com/educacao/noticia/2025/09/09/51percent-dos-brasileiros-que-entram-na-faculdade-nao-se-formam-nem-3-anos-apos-o-prazo-por-razo-por-revista.ghtml>
- [2] M. S. Pimentel, C. B. da Silva, F. F. B. Gomes, e J. V. C. Santos, “Análise de dados com machine learning: Classificação de alunos em risco de evasão escolar utilizando modelos de machine learning,” *Apoena*, vol. 7, pp. 81–97, 2023. [Online]. Available: <https://publicacoes.unijorge.com.br/apoena/article/view/154>
- [3] L. N. de Castro and D. G. Ferrari, *Introdução à mineração de dados: conceitos básicos, algoritmos e aplicações*. São Paulo, SP, Brasil: Saraiva, 2016.
- [4] V. Realinho, M. V. Martins, J. Machado, e L. Baptista, “Predict Students’ Dropout and Academic Success,” *UCI Machine Learning Repository*, 2021. [Online]. Available: <https://archive.ics.uci.edu/dataset/697/predict+students+dropout+and+academic+success>. DOI: 10.24432/C5MC89.
- [5] M. V. Martins, D. Tolledo, J. Machado, L. M. Baptista, and V. Realinho, “Early prediction of student’s performance in higher education: A case study,” in *Trends and Applications in Information Systems and Technologies*, vol. 1, Á. Rocha, H. Adeli, G. Dzemyda, F. Moreira, and A. M. R. Correia, Eds. Cham, Switzerland: Springer, 2021, pp. 166–175.
- [6] M. C. Sanches, *Data Science Final Project*, GitHub Repository, 2026. [Online]. Available: <https://github.com/mateuscostasanches/FinalProject-DataScience> [Accessed: May 19, 2026].